2024 年第三届“钉钉杯”大学生
大数据挑战赛论文

题　　目　基于模态分解和集成学习的烟草销售数据分析

摘　要

中国烟草行业具有严格的行政管控和专卖制度，因此相比其他行业，做好烟草销售的预测，是推进烟草行业生产和销售环节有效匹配的重要方式，也是为《关于建设现代化烟草经济体系推动烟草行业高质量发展的实施意见》提出的发展目标提供方法支撑。为实现对烟草销售的合理预测，本文在对数据进行特征提取、空缺值处理等数据预处理之后，先使用模态分解技术对烟草的销售数据进行分解以帮助模型更好学习到数据的特征，之后分别建立预测模型对不同品牌的香烟销售情况进行预测，最后构建集成学习模型实现对烟草销售的精准预测。

对于问题一，为实现对 A1、A2 品牌香烟未来销量的预测，本文首先通过**时变滤波的经验模态分解**(TVF-EMD)对相应数据进行模态分解，降低数据的非平稳性，之后对各模态分别建立**长短期神经网络**（LSTM）和**支持向量机回归**（SVR）预测模型并进行预测，最后将各个模态的预测结果进行重构得到最后预测结果。使用 RSME、R^2、MAE 评价指标对模型预测效果进行评价，可以发现本文所建立的模型的预测效果良好，预测结果比较可信。

对于问题二，本文需要实现对 A3、A4 品牌香烟未来销售金额的预测，不同于问题一的解题思路，本文首先使用**基于灰狼优化算法的变分模态分解**（GWO-VMD）对销售金额数据进行模态分解，之后对各模态分别建立**长短期神经网络**（LSTM）和**支持向量机回归**（SVR）预测模型并进行预测，将各个模态的预测结果进行重构后得到最终预测结果。采用 RSME、R^2、MAE 评价指标对模型预测效果进行评价，可以发现本文在该问题建立的预测模型效果良好，较好满足本文的研究目的。

对于问题三，本文对 A5 品牌香烟的销量和销售金额进行联合预测，首先使用**皮尔逊相关系数**和 **K-W 非参数检验**证明了 A5 品牌香烟的销量和销售金额之间存在显著相关性，之后使用**时变滤波的经验模态分解**对时间序列数据进行模态分解，然后使用**堆叠法**融合 LSTM、SVR 等预测模型形成**集成学习模型**，通过该集成学习模型对各模态分别进行预测和重组得到香烟销量和销售金额的预测结果，最后考虑到销量和销售金额之间的强相互关系，本文使用销量和销售金额分别对对方的误差进行**修正**。同样采用各评价指标对模型进行评价，可以发现本文构建的集成学习模型在本问题的预测上表现极为优异，本文的研究目的得以较好实现。

在本次研究中，本文综合运用模态分解技术和 LSTM、SVR 等多种时间序列预测方法，并在此基础上使用堆叠法构建集成学习模型，实现了对烟草销售的精准预测。本文的预测模型将有利于国家持续推进烟草专卖制度，实现最优的社会目标和经济目标。

关键词：烟草营销；模态分解技术；时间序列预测；集成学习

目录

一、 问题重述 1
1.1 问题背景 1
1.2 题目信息 1
1.3 待求解问题 1
二、 问题分析 1
2.1 问题一的分析 2
2.2 问题二的分析 2
2.3 问题三的分析 2
三、 模型假设及符号说明 2
3.1 模型假设 2
3.2 符号说明 2
四、 数据预处理及探索性分析 3
4.1 数据预处理—线性插值 3
4.2 数据结构挖掘 4
4.2.1 数据结构 4
4.2.2 自相关分析 5
五、 问题一及问题二模型的建立与求解 7
5.1 模型的建立 7
5.1.1 时变滤波的经验模态分解（TVF_EMD） 7
5.1.2 基于灰狼优化算法的变分模态分解（GWO-VMD） 8
5.1.3 LSTM 算法 9
5.1.4 支持向量机 9
5.2 问题一的求解 10
5.2.1 TVF_EMD 模态分解结果 10
5.2.2 基于 LSTM 模型的 A1 销量数据预测 11
5.2.3 基于 SVR 模型的 A2 销量数据预测 12
5.3 问题二模型的求解 14
5.3.1 GWO-VMD 模态分解结果 14
5.3.2 基于 LSTM 模型 A3 销售金额的求解 15
5.3.3 基于 SVR 模型的 A4 销售金额的求解 16
六、 问题三模型的建立和求解 17
6.1 模型的建立 18
6.1.1 皮尔逊相关系数 18
6.1.2 K-W 非参数检验模型 18
6.1.3 基于堆叠法的集成学习算法 18
6.2 销量与销售金额的相互关系检验 19
6.2.1 皮尔逊相关系数 19
6.2.2 K-W 非参数检验 19
6.3 基于集成学习的模型预测 19
6.3.1 销量的模型预测 19
6.3.2 销售金额的模型预测 20
6.3.3 预测结果修正 21

九、 模型优缺点分析 23
9.1 优点 23
9.2 缺点 24
参考文献.....24
附录 25

一、问题重述

1.1 问题背景

在国家财政收入的版图中，烟草税收占据着举足轻重的地位。鉴于其对社会与经济的深远影响，我国对烟草行业实行了严格的专卖制度，确保了从生产到流通的每一个环节都在国家的监管之下。随着时间的推移，卷烟销售收入呈现出稳步增长的趋势，这不仅反映了烟草市场的需求稳定性，也突显了对市场动态进行精准分析的必要性。

倘若无法对烟草营销数据进行有效预测分析，可能导致库存积压或缺货，增加存储成本和过时风险，也可能导致错失销售机会和顾客不满。不准确的预测还可能影响收入预测、成本控制和利润率，进而影响公司的投资决策和风险管理。在竞争激烈的市场中，把握市场走向才是获得竞争优势的关键，市场把控上的失误可能导致公司在市场竞争中处于不利地位，降低品牌忠诚度和市场声誉。

鉴于此，烟草行业的营销策略亟需依托于科学、系统的数据分析，以预测市场动向，优化库存管理，制定有效的销售策略。本文着眼于某地区近年来的烟草销售数据，旨在通过深入分析，揭示销售趋势，评估市场潜力，并为未来的销售活动提供数据支持。

1.2 题目信息

题目围绕烟草营销案例的数据分析，提出了对未来销量及销售金额的预测任务，并且是单变量的时间序列预测任务。数据集涵盖了五个品牌的烟草产品，每个品牌的数据均以 Excel 文件的形式提供，共包含五个文件，每文件包含五列数据，记录了产品的销售月份、样品代码、名称、销量（箱）和销售总金额。五种烟草的销量和单价间均存在明显差异，且销售数据包含一定的周期性、季节性特征。数据已经过脱敏和变换处理，但观察到某些品牌烟草数据在部分月份存在缺失，甚至部分年份存在缺失，增加了预测的不确定性。

1.3 待求解问题

1.需要进行销量预测分析，利用历史销售数据，构建时间序列预测模型，对未来烟草产品的销量进行准确预测。具体目标是预测 A1 和 A2 香烟品牌在空白月份的销量，确保模型的可拓展性和实用性。

2.需要进行销售金额预测分析，基于历史销售数据，构建适用于 A3 和 A4 香烟品牌的销售金额预测模型，目标是预测这些品牌在空白月份的销售收入，并确保模型具有良好性能及泛化能力。

3.需要进行集成学习模型构建，在销量和销售金额预测的基础上，进一步构建集成学习模型，实现对 A5 香烟品牌的销量和销售金额的联合预测。该模型将综合考虑不同预测模型的优势，以提高预测的准确性和鲁棒性。

二、问题分析

本题主要要求为分别建立预测模型对 5 种不同品牌的销售数据进行预测，其中对 A5

品牌香烟销售数据的预测要求进一步构建集成学习模型实现联合预测。查看题目给出的5个数据集，可以发现部分数据集的时间序列数据并不连续，因此需要通过插值法进行补充。而要想构建预测模型，理解数据特征是重中之重，因此在完成数据预处理后，有必要进行探索性数据分析以帮助我们更好理解数据特征，选择合适的预测模型。

2.1 问题一的分析

问题一要求分别构建两个时间序列预测模型对 A1、A2 香烟品牌的销量进行预测，而学习好数据的特征和选择适合的预测模型是实现精准预测的方向和关键。基于这一考虑，本文首先需要分解出时间序列数据的变化特征，之后在此基础上分别选择两个时间序列预测模型对数据进行预测。希望通过数据特征分解和选择合适的时间序列预测模型，本文可以实现较好的预测效果。

2.2 问题二的分析

问题二的基本思路与问题一类似，本文首先需要采取一定方法对数据进行分解，以帮助模型更好理解和学习数据，之后在此基础上，选择两个合适的时间序列预测模型对A3、A4 品牌香烟的销售金额数据进行预测。

2.3 问题三的分析

问题三要求通过集成学习对 A5 香烟的销量和销售金额进行联合预测，该问题实际上包含两个要求，第一个是构建集成学习模型进行预测，第二个是要求预测过程应该考虑销量和销售金额之间的关系。因此，本文首先需要分析销量和销售金额之间是否存在较强的相互关系，之后使用堆叠法实现对多个预测模型的集成并进行预测，最后考虑销量和销售金额之间的关系，本文需要对预测结果进行进一步修正。

三、模型假设及符号说明

3.1 模型假设

1.假设题目所给五种烟草的销量和销售金额真实可信。

2.假设在研究的时间范围内，市场情况没有发生诸如政策调整或经济转型等较大变动。

3.假设消费者对烟草产品的购买行为能够适应市场变化，如价格波动、税收政策调整以及健康意识的提高等。这意味着在预测模型中，我们将考虑消费者行为的动态性，以及他们对市场信号的响应速度和程度。

3.2 符号说明

符号	符号含义
$Q_{i,t}$	第 i 种烟草第 t 个时间点的销量（箱）
$P_{i,t}$	第 i 种烟草第 t 个时间点的销售金额（元）

$IMF_{i,j,k}$	第 i 种烟草第 j 个变量第 k 个模态分量
RSME	均方根误差
R2	决定系数
MAE	平均绝对误差

四、数据预处理及探索性分析

4.1 数据预处理—线性插值

由于部分数据中存在月份数据的缺失，我们采用插值的方式对数据进行初步处理。如图所示，红色为线性插值，粉色为三次样条。在考虑时间序列插值时，线性插值和三次样条插值各有其优点。由于本文的时间序列数据在缺失点附近的变化趋势相对平稳，在保持一定精度的情况下，我们选择线性插值。同时，在观察 A5 数据发现 2018 年 9 月至 2022 年 12 月一个大区间和一些小时间点的数据存在缺失，考虑到数据的季节性和周期性特征，本文去掉 2019-2022 年的数据，对 2018 年 9 月到 2018 年 12 月的数据利用集成学习填补，其他缺失值利用线性插值填补。（由于篇幅限制，此处只展示 A1 至 A4 销量数据的插值结果）

图 1　A1 数据集的销量数据插值结果

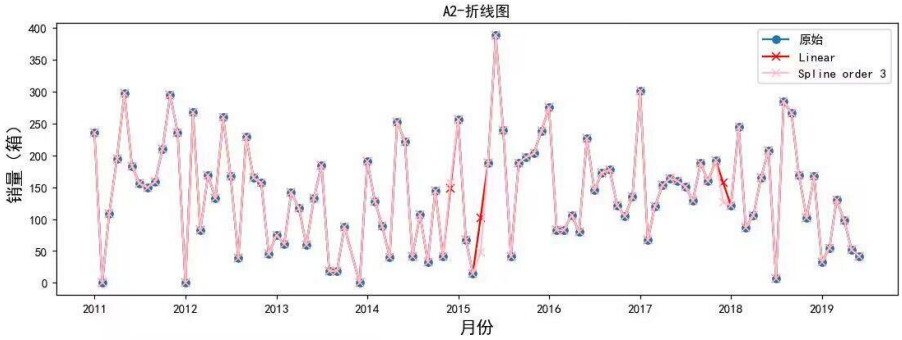

图 2　A2 数据集的销量数据插值结果

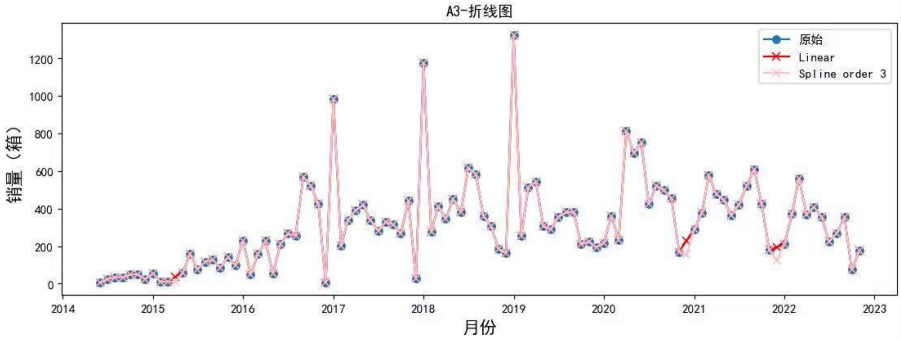

图 3　A3 数据集的销量数据插值结果

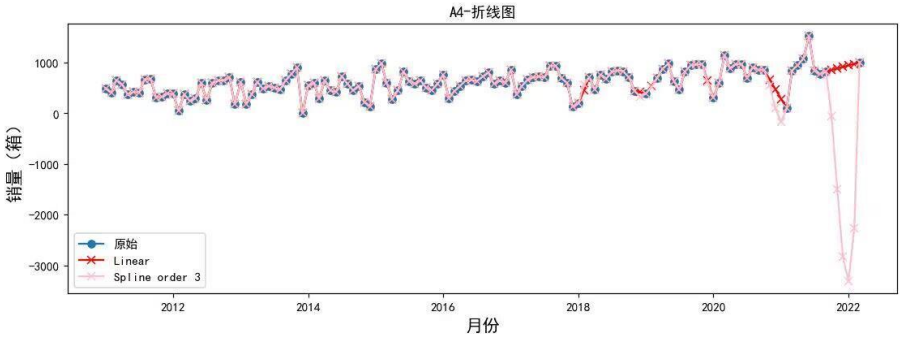

图 4　A4 数据集的销量数据插值结果

4.2 数据结构挖掘

4.2.1 数据结构

插值后的数据情况如下图所示，如图所示，时间序列数据如 A1 存在较为明显的下降趋势，A4 呈现较为明显的上升趋势，且可见其存在较为显著的周期性特征，故后续研究其滞后性和自相关性。为解决数据的异常值和平稳性，后续通过模态分解的方式去除部分噪声和异常数据，实现时间序列平稳预测。由于上文提到 A5 数据集存在的特殊性，此处针对 A1～A4 数据集进行描述。

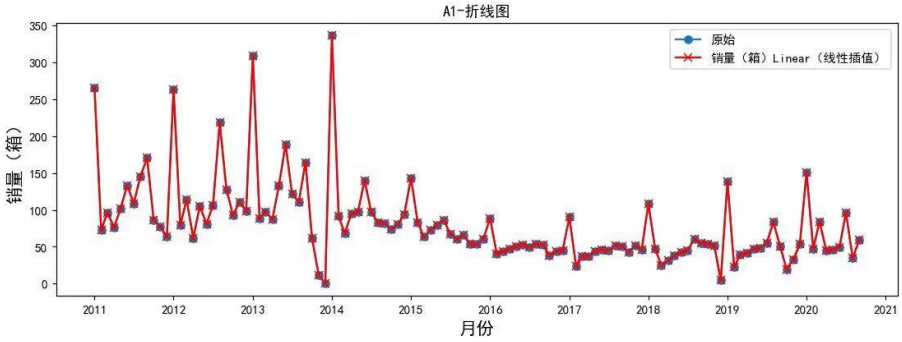

图 5　A1 销量数据折线图

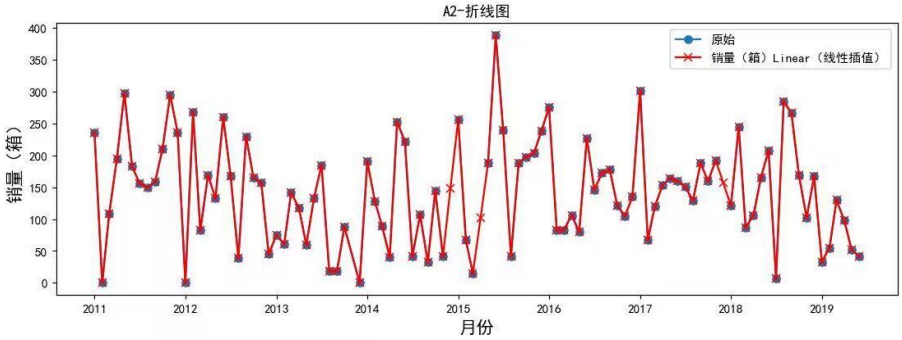

图 6 A2 销量数据折线图

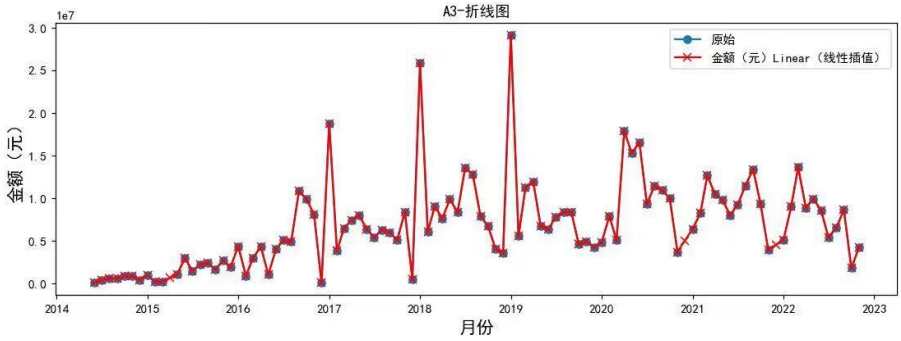

图 7 A3 销售金额数据折线图

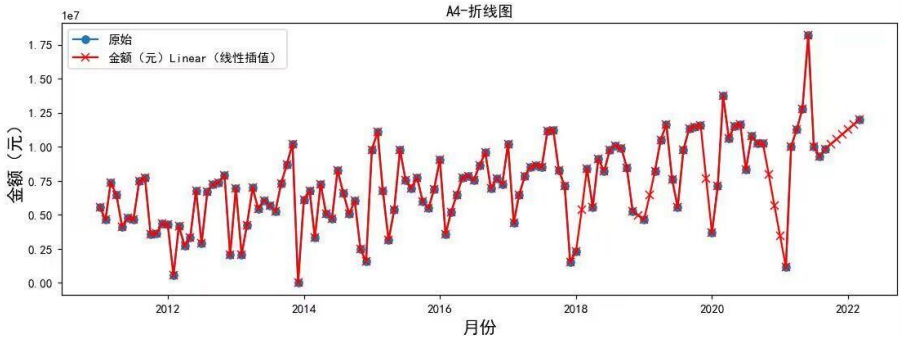

图 8 A4 销售金额折线图

4.2.2 自相关分析

自相关系数帮我们确定了时间序列数据是否存在依赖性、周期性和随机性。通过自相关系数的分析，自相关系数接近 1，说明现在的数据与过去数据之前存在较强的关系，相隔峰值之间的距离较近，故可能存在一定的周期特征，具体分析 12 个月可能是它的一个周期。

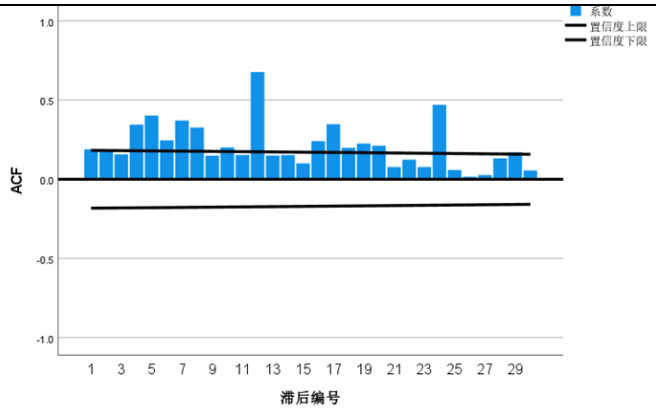

图 9 A1 的自相关系数

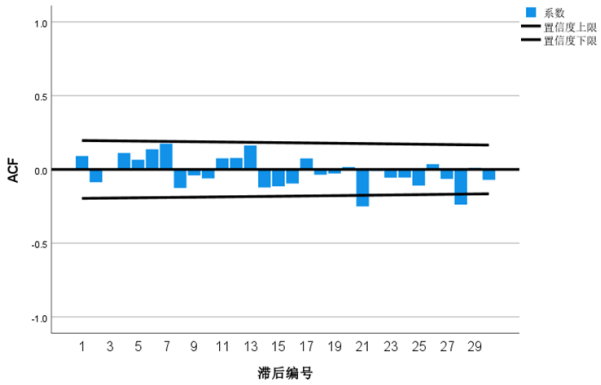

图 10 A2 的自相关系数

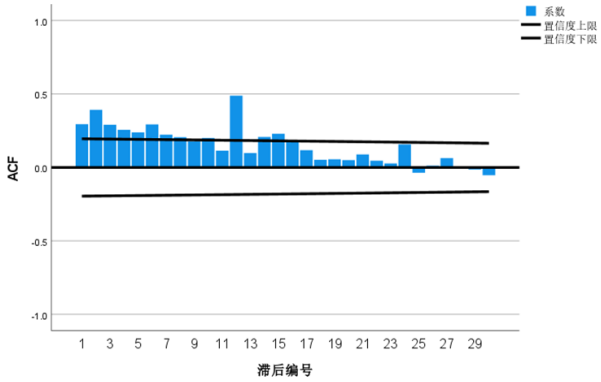

图 11 A3 的自相关系数

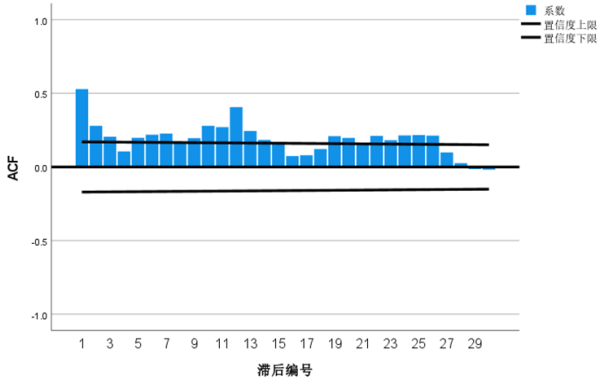

图 12 A4 的自相关系数

五、问题一及问题二模型的建立与求解

5.1 模型的建立

5.1.1 时变滤波的经验模态分解（TVF_EMD）

经验模态分解（Empirical Mode Decomposition, EMD）是一种自适应的时频分析方法，它通过分解信号为一系列固有模态函数（Intrinsic Mode Functions, IMFs），来捕捉信号的局部时频特征。时变滤波的经验模态分解（Time-Varying Filter EMD, TVF-EMD）是在传统 EMD 的基础上，引入时变滤波器来增强分解效果的一种改进方法。传统数据分解方法(EMD)在某些情况下存在一定的局限性，有时会出现分解不全面或过度分解的现象，TVF-EMD 方法能够改善传统数据分解方法存在的缺陷，能够根据时变滤波的经验模态分解出信号的模式。这种筛选过程是通过时变滤波来实现的，给定信号x(t)被分解成有限数量的IMF 和残差$r(t)$, 如公式(1)所示。

$$x(t)=\sum_{i=1}^{n} i\,mf_i(t)+r(t) \tag{1}$$

其中，$imf_i(t)$表 示第i个IMF ，时变滤波经验模态分解方法具体步骤如下：

(1)求出$x(t)$的极大值，表示为$u_i(i=1,2,3\cdots)$

(2)求出间断点$e_j, j=1,2,3\cdots$。存在阈值ρ满足公式(2)，此时间断点$\mathrm{e_j}=\mathrm{u_i}$。

$$\frac{max[\varphi'_{bis}(u_i\le t\le u_{i+1})]-min[\varphi'_{bis}(u_i\le t\le u_{i+1})]}{min[\varphi'_{bis}(u_i\le t\le u_{i+1})]}>\rho \tag{2}$$

其中$\varphi'_{bis}(t)$表 示二等分频率，ρ是两个连续最大值之间频率变化率的预设阈值。若$\varphi'_{bis}(u_{i+1})-\varphi'_{bis}(u_i)>0$,则 间断点$e_j$位于上升沿，$\varphi'_{bis}\left(e_{(j-1)}\leqslant t\leqslant e_{(j)}\right)$是最小值；若$\varphi'_{bis}(u_{i+1})-\varphi'_{bis}(u_i)<0$,则间断点$e_j$位于下降沿，$\varphi'_{bis}\left(e_{(j)}\le t\le e_{(j+1)}\right)$是最小值。$\varphi'_{bis}(t)$的其余部分可视为峰值。

(3)求出局部截止频率$\varphi'_{bis}(t)$。 在峰值之间插值得到$\varphi'_{bis}(t)$, 调整$\varphi'_{bis}(t)$改善模态混叠。

(4)重构$\varphi'_{bis}(t)$, 得到新信号$h(t)$。

$$h(t)=cos\left[\int \varphi'_{bis}(t)dt\right] \tag{3}$$

(5)用 B- spline 近似滤波器对输入信号$x(t)$进行滤波，得到局部均值函数。

(6)计算准则值$\theta(t)$, 判断残留信号是否符合截止标准。

$$\theta(t)=\frac{B_{\mathrm{Loughin}}(t)}{\varphi_{\mathrm{avg}}(t)} \tag{4}$$

其中$B_{\mathrm{Loughin}}(t)$表示 Loughlin 瞬时带宽，$\varphi_{\mathrm{avg}}(t)$表示加权平均瞬时频率。存在一个带宽阈值$\varepsilon$, 如果$\theta(t)\le\varepsilon$, 则该信号为局部窄带信号，即一个分量信号$IMF$。

5.1.2 基于灰狼优化算法的变分模态分解（GWO-VMD）

VMD 可以用于分解时间序列，与 TVF-EMD 不同，它采用变分原理来分解时间序列，可以较好处理非平稳性和混沌性强地时间序列，减少模态混叠。其主要原来是将信号分解成多个中心频率为的子模态，并按照它们中心频率进行排序。。VMD 的分解过程是通过变分问题的优化实现的，其基本步骤如下：

步骤一：构造变分问题，其目标是在所有分解得到的模态之和等于原始信号的约束下，使每个模态的估计带宽之和最小。因此可以构建以下最优化问题：

$$\min\left\{\sum_{k=1}^{K}\left\|\partial_t\left[\left(\delta(t)+\frac{j}{\pi t}\right)*u_k(t)\right]e^{-jw_k t}\right\|_2^2\right\} \tag{5}$$

$$s.t.\sum_{k=1}^{K}u_k(t)=S(t) \tag{6}$$

上式中，u_k和w_k分别表示第 k 个模态分量和中心频率，∂_t代表偏导数的计算，$\delta(t)$是单位脉冲函数，j 代表叙述单位，$*$是卷积运算，S(t)表示原始信号，$\|\cdot\|_2^2$表示模态梯度 L2 范数的平方。

步骤二：求解变分表达式。在上述目标函数的基础上构建增广 Lagrangr 表达式：

$$\begin{aligned}L[\{u_k(t)\},\{w_k\},\{\lambda(t)\}]&\\ =\alpha\sum_{k=1}^{K}\left\|\partial_t\left[\left(\delta(t)+\frac{j}{\pi t}\right)*u_k(t)\right]e^{-jw_k t}\right\|_2^2&+\left\|S(t)-\sum_{k=1}^{K}u_k(t)\right\|_2^2\\ +\langle\lambda(t),S(t)-\sum_{k=1}^{K}u_k(t)\rangle&\end{aligned} \tag{7}$$

其中，α代表惩罚因子，λ代表 Lagrange 惩罚算子。

步骤三：对增广 Lagrange 表达式的鞍点进行求解。在对参数u_1、w_1、λ_1、n 初始化后，根据式（8）～（11）更新u_k、w_k、λ_k，循环次数为 n+1，当变量满足约束条件式(7)时完成求解

$$\hat{u}_k^{n+1}(w)=\frac{\hat{S}(w)-\sum_{i\neq k}\hat{u}_i(w)+\frac{\hat{\lambda}(w)}{2}}{1+2\alpha(w-w_k)^2} \tag{8}$$

$$w_k^{n+1}=\frac{\int_0^\infty w|\hat{u}_k(w)|^2}{\int_0^\infty|\hat{u}_k(w)|^2} \tag{9}$$

$$\hat{\lambda}^{n+1}(w)=\hat{\lambda}^n(w)+\tau\left(\hat{S}(w)-\sum_{k=1}^{K}\hat{u}_k^{n+1}(w)\right) \tag{10}$$

$$\sum_{k=1}^{K}\frac{\|n_k^{n+1}-u_k^n\|_2^2}{\|u_k^n\|_2^2}<\varepsilon \tag{11}$$

(3)

上式中，$\hat{S}$、$\hat{u}$、$\hat{\lambda}$代表傅里叶变换，τ代表保真系数，n 为迭代次数。

在使用 VMD 分解信号时，需要给 VMD 设置分解模态数 K 和惩罚因子α这两个重要参数，它们将直接影响模态分解效果，因此有必要寻找最优参数以提高 VMD 的分解效能。包络熵是一种衡量信号包络的复杂度和不确定性的指标，能够较好地评判 VMD 的分解效

果，因此本文将其作为适应度函数，当其达到最小时，则能得到最优参数组合 K 和α，其计算公式如下所示：

$$\langle\hat{\alpha},\hat{K}\rangle = \arg\left\{\frac{1}{\hat{K}}\sum_{i=1}^{\hat{K}} E_p\right\} \tag{12}$$

式（12）中，$\langle\hat{\alpha},\hat{K}\rangle$表示最优惩罚因子和分解模态数的参数组合，$E_p$表示包络熵。灰狼优化算法（GWO）具有参数少、收敛性强等特征，可以高效地获取和积累搜索空间地知识，以快速获得最优解，近年来被广泛运用于模型参数的优化。它模仿灰狼的社会等级和捕食策略，首先定义 3 匹最好的狼（最优解）α狼、β狼和δ狼，并定义其余狼（候选解）为ω狼，其余狼在α狼、β狼和δ狼指挥下，通过追捕、包围和攻击猎物的方式逐步逼近最优解。通过引入灰狼优化算法，本文可以快速求得最优参数组合以实现最优分解，因此本文采取它求解式（12）。

5.1.3 LSTM 算法

具体步骤如下：

（1）初始化网络的权重和偏置项

（2）按时间步长逐一接收输入序列

（3）计算输入门值和输入单元候选状态值:

$$I_t = \mu(L_I\ \ (X_t, y_{t-1}) + b_I) \tag{13}$$

$$A'_t = tany(L_c\ \ (X_t, y_{t-1}) + b_c) \tag{14}$$

（4）计算此时的遗忘门激活值和单元状态更新值:

$$F_t = \mu(L_F\ \ (X_t, y_{t-1}) + b_F) \tag{15}$$

$$A_t = I_t\ \ A'_t + F_t\ \ A_{t-1} \tag{16}$$

（5）最后，计算输出门的值

$$Q_t = \mu(L_Q\ \ (X_t, y_{t-1}) + b_Q) \tag{17}$$

$$y_t = Q_t\ \ tany(A_t) \tag{18}$$

5.1.4 支持向量机

支持向量机是一种适合于小样本的监督学习模型，具体步骤如下：

给定训练集$D = \{(x_1,y_1),(x_2,y_2),\ldots,(x_m,y_m)\}$（m 为数据量），定义设 z 为每个样本点到 f（x）的距离，仅当$|z| > \varepsilon$时才算损失，损失函数$L_\varepsilon(z)$表示为

$$L_{\varepsilon}(z)=\begin{cases}0 & ,|z|\le\varepsilon\\ |z|-\varepsilon, & |z|>\varepsilon\end{cases} \tag{19}$$

引入松弛变量ξ_i和ξ_i（ξ_i，$\hat{\xi}_i\ge 0$）,表示为

$$\begin{cases} min\frac{1}{2}\|\omega\|^2+c\sum_{i=1}^{m}(\xi_i+\hat{\xi}_i)\\ s.t.f(x_i)-y_i\le\varepsilon+\xi_i\\ y_i-\ f(x_i)\le\varepsilon+\hat{\xi}_i\end{cases} \tag{20}$$

其中，ξ_i表示预测值与缓存区域上边界的距离；$\hat{\xi}_i$表示预测值与缓存区域下边界的距离；ω表示决策平面的法向量；c 表示常数。

（3）引入拉格朗日乘子（a_i和$\hat{a}_i$），并求偏导代入 SVR 对偶问题，得到 SVR 的公式为：

$$f(x)=\ \sum_{i=1}^{m}(a_i+\hat{a}_i)\,\omega^T x+b \tag{21}$$

其中，b 为超平面上的截距变量。

5.2 问题一的求解

5.2.1 TVF_EMD 模态分解结果

对于问题一用到的 A1、A1 数据集的“销量（箱）”数据进行初步分析可以发现，该时间序列数据存在非平稳性和非线性特征。如果直接使用该数据进行训练和预测，其包含的噪声和扰动会对模型的学习产生较大的影响，导致预测结果精度较低。针对本问题数据的特点，本文使用前面构建的 TVF_EMD 对 A3、A4 数据集的“金额（元）”数据进行分解，以帮助预测模型更好学习该数据的趋势和周期性等特征。结果如图 13 和图 14 图 20 所示。

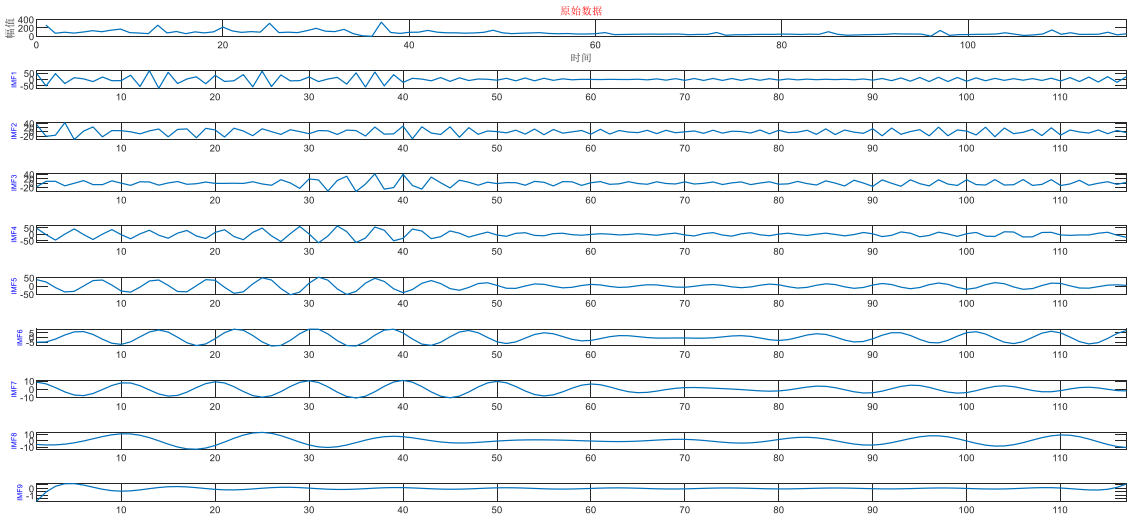

图 13 A1“销量（箱）”模态分解结果图

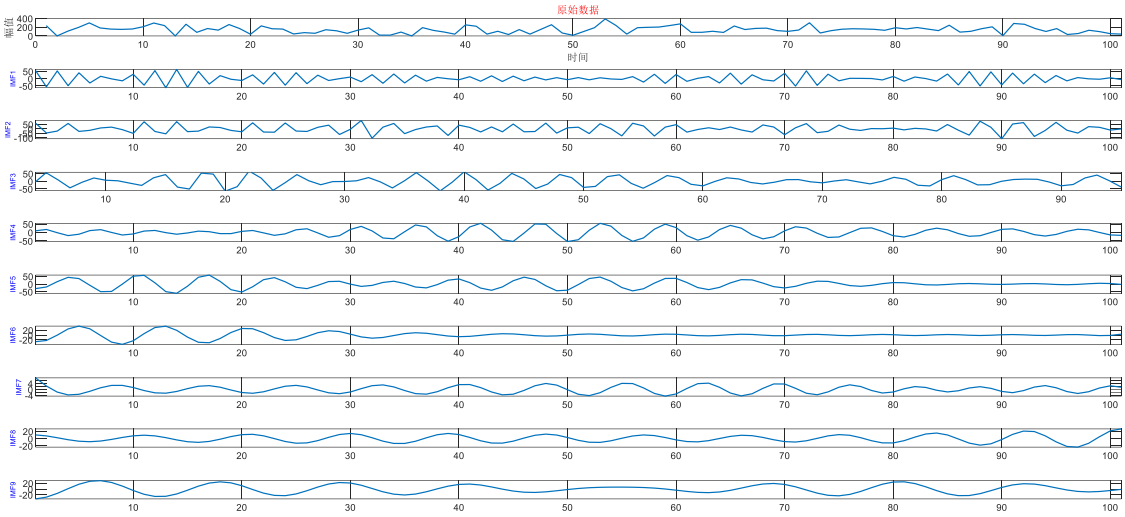

图 14 A2“销量（箱）”模态分解结果图

由图 13 和图 14 可知，通过 TVF_EMD，本文较好地分解出 A1 和 A2“销量（箱）”时间序列的 IMF 分量，之后本文将分别使用时间序列模型学习每个分量的特征并进行预测，最后对每个分量的预测结果加总得到最终预测结果。

5.2.2 基于 LSTM 模型的 A1 销量数据预测

对于 A1 销量的预测，本文采用前面构建的 SVR 模型进行训练和测试，设置时间窗口为 12 个月，其训练和测试效果以图 15 展示。

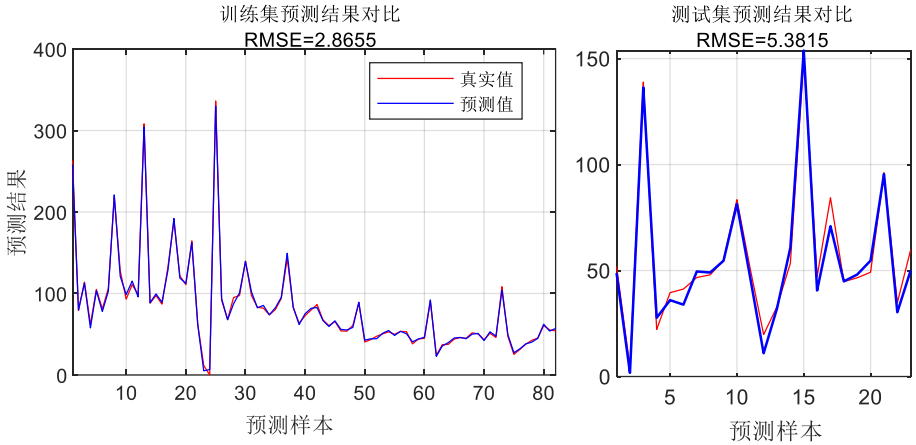

图 15 基于 LSTM 模型的 A1 销量预测模型效果图

通过图 15 可以发现，训练完成后的 LSTM 对训练集和测试集的预测效果基本和原始数据的趋势相近。同时通过 RSME（均方根误差）、R2（决定系数）、MAE(平均绝对误差)对测试集预测结果进行评价，由表 1 所示，发现各项指标较为良好，其中 R^2 达保持在 0.97 左右，说明本模型的准确率较高，模型的泛化能力较强，能帮助本文实现较精准的预测以解决问题。

表 1 基于 LSTM 模型的 A1 销量预测模型评价结果

评价指标	训练集	测试集
RSME（均方根误差）	2.8655	5.3815
R2（决定系数）	0.99747	0.9745
MAE(平均绝对误差)	2.2669	4.2376

最后，本文使用该训练好的 LSTM 模型对题目一要求的 A1 香烟 2020 年 10 月到 2022 年 7 月的销售金额进行预测，具体数值结果如表 2 所示（由于 2021 年 1 月等时间点的预测未为在题目要求内，本文先预测出连续时间段后，将这些预测结果删除后展示）。同时本文将预测结果可视化为图 16，可以发现预测结果（红线）的趋势与原来的时间序列数据基本一致，存在峰值和低谷，因此该预测结果是有一定可信度的。

表 2 基于 LSTM 模型的 A1 销量预测结果

月份	A1 销量	月份	A1 销量
202010	50.03938	202109	48.50373
202011	40.27097	202110	48.4703
202012	86.38918	202111	21.60339
202102	23.68263	202112	55.83877
202103	33.15676	202202	68.34978
202104	102.9445	202203	23.99084
202105	64.63688	202204	63.87949
202106	45.67413	202205	66.47935
202107	18.12034	202206	71.22743
202108	74.93487	202207	19.26947

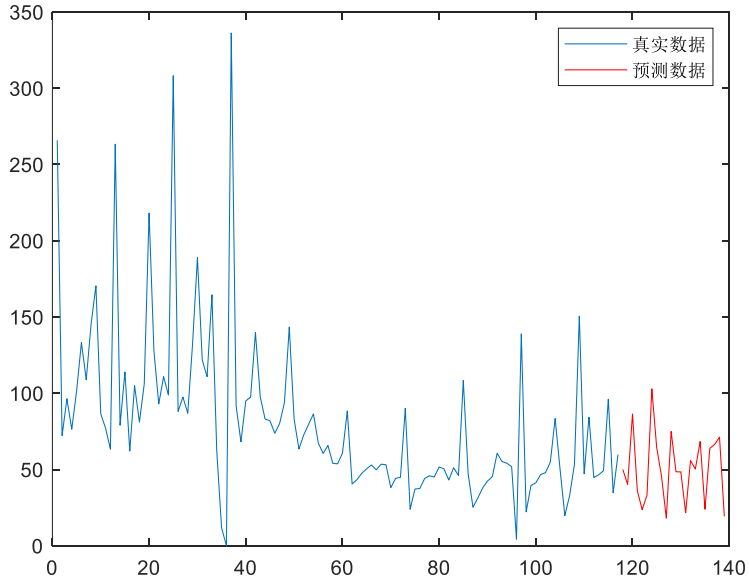

图 16 基于 LSTM 模型的 A1 销量预测结果可视化图

5.2.3 基于 SVR 模型的 A2 销量数据预测

对于 A2 销量的预测，本文采用前面构建的 SVR 模型进行训练和测试，设置时间窗口为 12 个月，其训练和测试效果以图 17 展示。

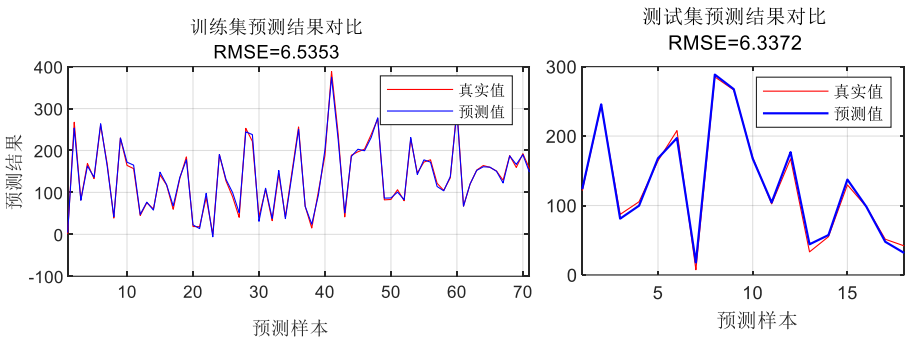

图 17 基于 SVR 模型的 A2 销量预测模型效果图

通过图 21 可以发现，训练完成后的 LSTM 对训练集和测试集的预测效果基本和原始数据的趋势相近。同时通过 RSME（均方根误差）、R2（决定系数）、MAE(平均绝对误差)对测试集预测结果进行评价，由表 3 所示，发现各项指标较为良好，其中 R^2 达保持在 0.99 左右，说明本模型的准确率高，模型的泛化能力优秀，能帮助本文实现较精准的预测以解决问题。

表 3 基于 SVR 模型的 A2 销量预测模型评价结果表

评价指标	训练集	测试集
RSME（均方根误差）	6.5353	6.3372
R2（决定系数）	0.9931	0.99367
MAE(平均绝对误差)	5.3376	5.1263

最后，本文使用该训练好的 SVR 模型对题目一要求的 A2 香烟 2019 年 7 月到 2020 年 5 月的销售金额进行预测，具体数值结果如表 4 所示（由于 2020 年 1 月时间点的预测未为在题目要求内，本文先预测出连续时间段后，将这些预测结果删除后展示）。同时本文将预测结果可视化为图 16，可以发现预测结果（红线）的趋势与原来的时间序列数据基本一致，存在峰值和低谷，因此该预测结果是有一定可信度的。

表 4 基于 SVR 模型的 A2 销量预测结果

月份	A2 销量
201907	32.08020649
201908	62.22618665
201909	85.2299206
201910	100.7737972
201911	104.166858
201912	20.8855664
202002	130.5358503
202003	154.960755
202004	209.4896505
202005	261.7930219

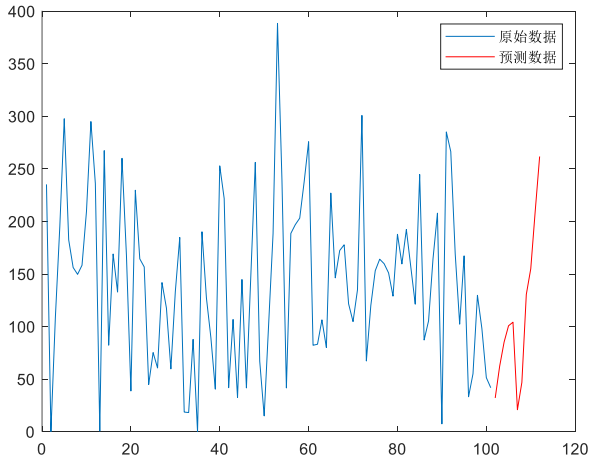

图 18 基于 SVR 模型的 A2 销量预测结果可视化图

5.3 问题二模型的求解

5.3.1 GWO-VMD 模态分解结果

对于问题二用到的 A3、A4 数据集的“金额（元）”数据进行初步分析可以发现，该时间序列数据存在非平稳性和非线性特征。如果直接使用该数据进行训练和预测，其包含的噪声和扰动会对模型的学习产生较大的影响，导致预测结果精度较低。针对本问题数据的特点，本文使用前面构建的 GWO-VMD 对 A3、A4 数据集的“金额（元）”数据进行分解，以帮助预测模型更好学习该数据的趋势和周期性等特征。结果如图 19 和图 20 所示，其中图 19 结果所需的最优参数组合为和，图 20 结果所需的最优参数组合为和。

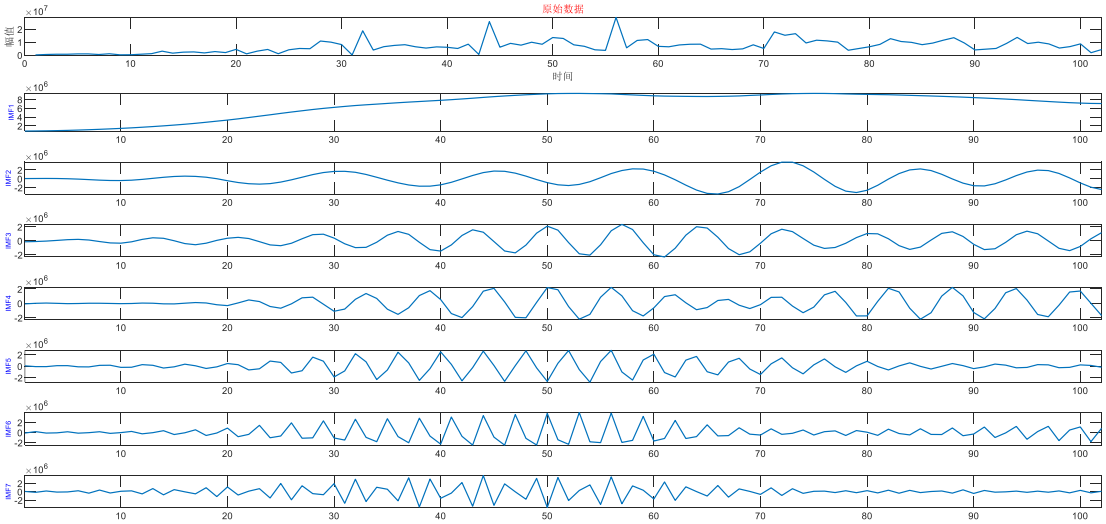

图 19 A3“金额（元）”模态分解结果图

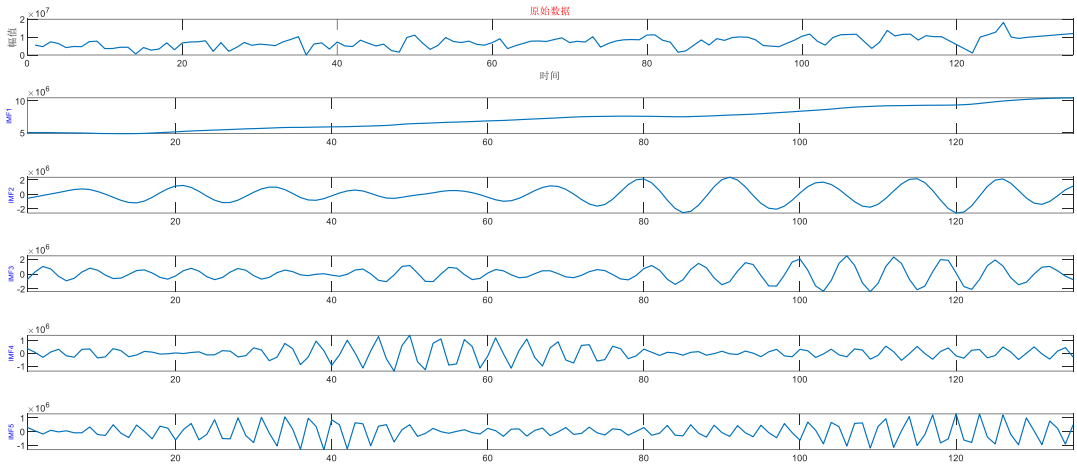

图 20 A4“金额（元）”模态分解结果图

由图 19 和图 20 可知，通过 GWO-VMD，本文较好地分解出 A3 和 A4“金额（元）”时间序列的 IMF 分量，之后本文将分别使用时间序列模型学习每个分量的特征并进行预测，最后对每个分量的预测结果加总得到最终预测结果。

5.3.2 基于 LSTM 模型 A3 销售金额的求解

对于 A3 销售金额的预测，本文采用前面构建的 LSTM 进行训练和测试，设置时间窗口为 12 个月，其训练和测试效果以图 21 展示。

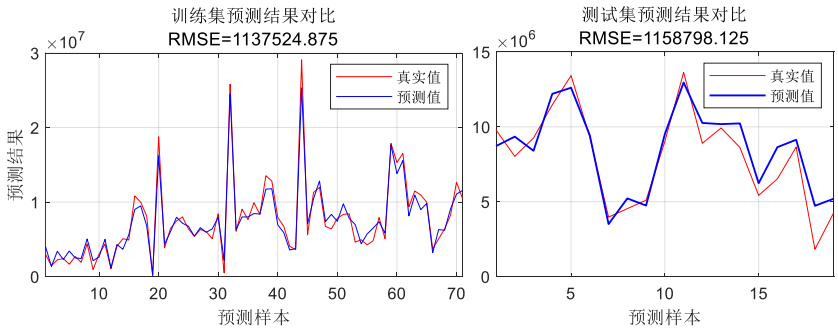

图 21 基于 LSTM 的 A3 销售金额预测效果图

通过图 21 可以发现，训练完成后的 LSTM 对训练集和测试集的预测效果基本和原始数据的趋势相近。同时通过 RSME（均方根误差）、R2（决定系数）、MAE(平均绝对误差)对测试集预测结果进行评价，由表 5 所示，发现各项指标较为良好，其中 R^2 达到 0.844，说明本模型的准确率较高，模型的泛化能力较强，能帮助本文实现较精准的预测以解决问题二。

表 5 基于 LSTM 的 A3 销售金额预测模型评价结果表

评价指标	训练集	测试集
RSME（均方根误差）	1.1375e+06	1.1588e+06
R2（决定系数）	0.95307	0.86116
MAE(平均绝对误差)	1.1588e+06	9.5006e+05

最后，本文使用该训练好的 LSTM 模型对题目二要求的 A3 香烟 2023 年 2 月到 2023 年 11 月的销售金额进行预测，具体数值结果如表 6 所示。同时本文将预测结果可视化见，可以发现预测结果（红线）的趋势与原来的时间序列数据基本一致，存在峰值和低谷，因此该预测结果是有一定可信度的。

表 6 基于 LSTM 的 A3 销售金额预测结果

月份	A2 销量
202302	4236989.297
202303	10388790.45
202304	7877941.328
202305	8215735.42
202306	10771632.02
202307	13428847.25
202308	11686569.92
202309	14443384.14
202310	10799224.66
202311	4671920.42

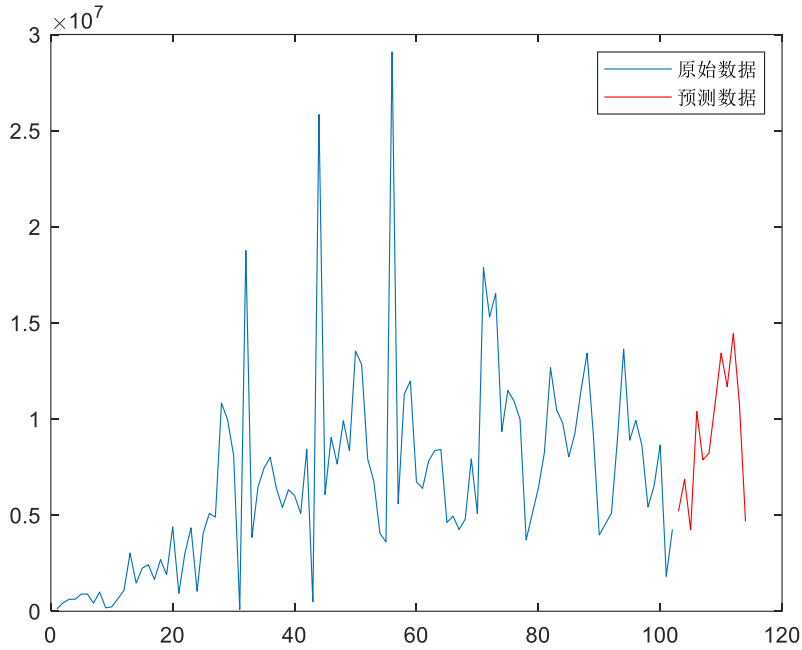

图 22 基于 LSTM 模型的 A3 销售金额预测结果可视化图

5.3.3 基于 SVR 模型的 A4 销售金额的求解

对于 A4 销售金额的预测，本文采用前面构建的 SVR 进行训练和测试，设置时间窗口为 12 个月，其训练和测试效果如图 23。

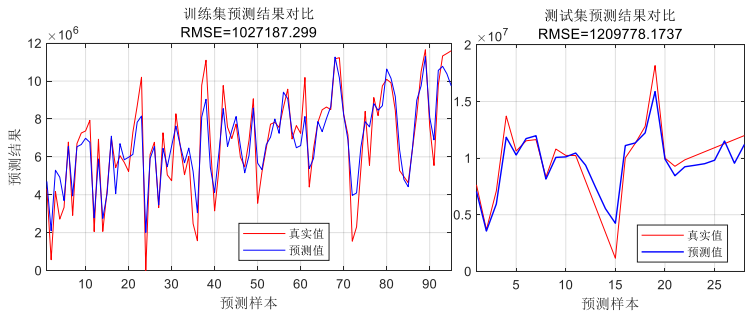

图 23 基于 SVR 的 A4 销售金额预测模型效果图

通过图 23 可以发现，SVR 基本上捕捉到了 A4“金额（元）”数据的变化趋势，通

过 RSME（均方根误差）、R2（决定系数）、MAE(平均绝对误差)对测试集预测结果进行评价，由表 7 所示，其中 R^2 达到 0.840，因此本模型的表现较好。

表 7 基于 SVR 的 A4 销售金额预测模型评价结果表

评价指标	训练集	测试集
RSME（均方根误差）	1.0272e+06	1.2098e+06
R2（决定系数）	0.84933	0.86557
MAE(平均绝对误差)	0.86557	9.2323e+05

根据问题二的要求，本文使用前面构建并完成训练的 SVR 对 A4 香烟 2022 年 4 月到 2024 年 1 月的销售金额进行预测，具体数值结果如表 8 所示。同时，对预测结果可视化得到图 24，可以发现，预测结果基本保持了历史数据的变化特征，因此该预测结果是具有一定可信度的。

表 8 基于 SVR 的 A4 销售金额预测结果

日期	金额（元）
202204	11275131.94
202205	11269492.25
202206	10408007.64
202207	11891886.19
202209	10122080.87
202301	9272214.41
202302	10129509.99
202303	12279682.84
202304	10114151.19
202306	9394437.668
202312	9544584.394
202401	8939390.357

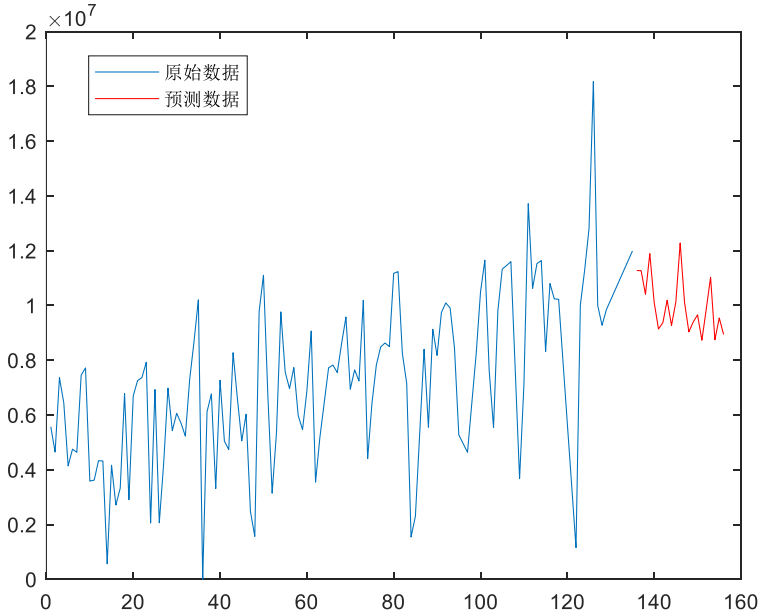

图 24 基于 SVR 的 A4 销售金额预测结果图

六、问题三模型的建立和求解

6.1 模型的建立

6.1.1 皮尔逊相关系数

皮尔逊相关系数（Pearson correlation coefficient），又称皮尔逊积矩相关系数（Pearson product-moment correlation coefficient，简称 PPMCC 或 PCCs），是统计学中用于度量两个变量 X 和 Y 之间线性相关程度的指标。计算公式为：

$$\left[r = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum(X_i - \bar{X})^2 \sum(Y_i - \bar{Y})^2}}\right] \tag{22}$$

其中，(r) 是相关系数，(X_i) 和 (Y_i) 分别是两个变量的观测值，$(\bar{X})$ *和* $(\bar{Y})$ 分别是两个变量的均值。

6.1.2 K-W 非参数检验模型

K-W 非参数检验，全称为 Kruskal-Wallis 检验（简称 K-W 检验或 H 检验），是一种用于检验两个以上独立样本是否来自同一概率分布的非参数方法。与单因素方差分析（ANOVA）类似，但 K-W 检验不假设样本来自正态分布。

基本原理 K-W 检验是一种秩检验，是威尔科克逊检验的推广，用于多个连续型独立样本的比较。 它不依赖于数据的具体分布形态，仅要求数据具有顺序（排序）测量尺度。 检验步骤 将各样本的全部观测值按递增顺序排列成一列。 计算每个样本中观测值在排列中的秩的和（即每个样本的秩统计量）。 使用这些秩统计量计算 K-W 检验的统计量 H。 根据给定的显著性水平（如 α=0.05）和自由度（通常为样本数减 1），查找相应的临界值或使用统计软件来判断 H 值是否显著。

6.1.3 基于堆叠法的集成学习算法

堆叠法(Stacking)是一种集成学习方法，它通过组合多个基学习器(base learners)的预测结果来训练一个最终的元学习器（meta-learner），以得到更加准确的预测。堆叠法的核心思想在于利用多个基学习器的多样性，通过元学习器来融合这些基学习器的预测结果，从而提高整体模型的预测性能。堆叠法中有两个学习器。基学习器：堆叠法中的基础模型，通常是多个不同的学习算法训练得到的。基学习器可以是任何类型的机器学习模型，如决策树、神经网络、支持向量机等。 元学习器：用于融合基学习器预测结果的最终模型。元学习器接收基学习器的预测结果作为输入，并输出最终的预测结果。元学习器通常选择简单且易于解释的模型，如逻辑回归、线性回归等。

堆叠法的执行步骤 训练基学习器：首先，在训练集上训练多个基学习器。这些基学习器可以是同质的（即使用相同的学习算法），也可以是异质的（即使用不同的学习算法）。 生成新训练集：将基学习器在训练集上的预测结果作为新的特征，与原始的训练集标签一起组成新的训练集。这个新的训练集将用于训练元学习器。 训练元学习器：使用上一步生成的新训练集来训练元学习器。元学习器的目标是学习如何将基学习器的预测结果融合起来，以得到更加准确的预测。 预测与评估：在测试集上，首先使用训练好的基学习器进行预测，然后将预测结果输入到元学习器中，得到最终的预测结果。最后，使用适当的评估指标来评估堆叠法模型的性能。

6.2 销量与销售金额的相互关系检验

6.2.1 皮尔逊相关系数

为初步确定 A5 数据中销量与销售数据之间的关系，从而更好地为预测模型构建作准备，本研究利用相关性分析分析 A5 数据销量与销售数据间的相关性，旨在说明利用两者间相关性互相进行预测并进行误差修正的合理性。基于此，本文使用斯皮尔曼相关系数共同说明两者间关系。肯德尔相关系数不依赖数据的具体分布形态，适合排序型变量之间的关系，但对异常值不够敏感，而斯皮尔曼相关系数能够识别变量间的单调关系，不受单位的影响。通过对肯德尔相关系数和斯皮尔曼相关系数的分析，本研究认为，销量和销售金额间存在显著的相关性，故认为能够进行第三问的预测。

6.2.2 K-W 非参数检验

为检验 A5 数据销售量和销售金额参数间的关系，本文采用 K-W 非参数估计对两者进行分析。在 KW 非参数检验（Kruskal-Wallis H 检验）中，检验统计（H 值)Kruskal-Wallis 检验的主要统计量，用于评估三个或更多独立组的中位数是否存在显著差异。它基于各组内观察值的秩次来计算。渐进显著性（也称为 P 值）是 KW 检验中用于判断观察到的数据差异是否具有统计学意义的关键指标。它表示在零假设（即所有组的中位数相等）为真的情况下，观察到当前或更极端结果的概率。

本研究中 P 值大于 0.5，故可以认为拒绝原假设，故两变量间存在显著的关系。

6.3 基于集成学习的模型预测

参考刘贤稳等的论文，本文基于上述模型的基础上，将预测数据放入多元预测模型进行集成学习，基于堆叠法的时间序列预测集成学习模型的建立过程如下：

（1）根据时间滑动窗口生成数据集；

（2）将数据集划分为 7：3 的训练集和测试集

（3）分别用 TVP_EMD_SVR、TVP_EMD_LSTM、GWO_SVM_SVR、GWO_SVM_LSTM 模型对数据集进行训练和预测，得到训练集拟合结果，测试集拟合结果，在通过多步预测的方法对未来的数据进行预测；

（4）见（3）的拟合结果作为自变量，真实结果作为因变量，进行集成学习模型(SVR 模型)的训练，最终预测出未来的数据；

6.3.1 销量的模型预测

根据上述建模过程对销量数据进行预测，模型训练效果见表 9。可以看出集成模型对数据的预测结果得到了提升，并且整体模型在训练集和测试集的效果均保持较高水平，泛化能力强，说明了本文的模型构建的有效性和合理性。

表 9 基于集成学习的 A5 销量预测模型训练效果

评价指标	模型 1		模型 2		模型 3		模型 4		集成模型	
RSME	6.6288	14.421	9.4807	15.0194	36.0535	42.3965	38.1751	41.5101	6.8455	12.1285

R2	0.99726	0.97967	0.9944	0.97795	0.91899	0.8243	0.90917	0.83157	0.99709	0.9877
MAE	-0.092097	7.7476	11.69	0.97945	27.9263	35.4785	29.542	34.549	5.4297	9.1075

最终预测结果见表 10 和图 25。

表 10 基于集成学习的 A5 销量预测结果

日期	销量（箱）
202306	629.95007
202307	239.91998
202308	206.62872
202309	307.20276
202310	340.4606
202311	274.68823
202401	139.70024
202402	474.38174
202403	145.85535
202404	318.97641

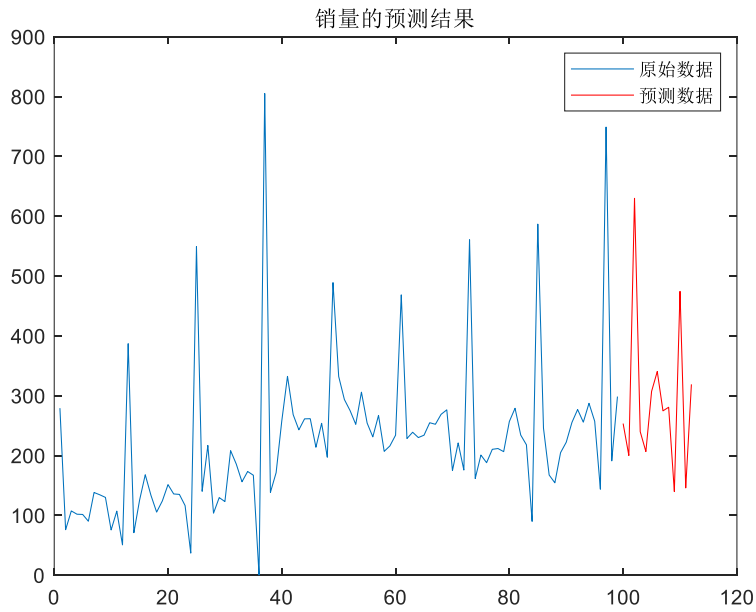

图 25 基于集成学习的销量预测结果

6.3.2 销售金额的模型预测

销售金额的预测模型构建同上。模型效果见表 11，预测结果见表 12 和图 26。

表 11 基于集成学习的 A5 销售金额预测模型训练效果

评价指标	模型 1		模型 2		模型 3		模型 4		集成模型	
RSME	7.8034	22.8721	10.2932	21.3402	47.3545	51.3047	47.5263	45.6544	7.6405	19.2758
R2	0.99593	0.97764	0.99291	0.98054	0.84997	0.8875	0.84887	0.91091	0.99651	0.9784
MAE	5.9355	18.9355	8.3271	17.8297	40.5784	42.9875	40.3856	40.0456	5.9291	15.3656

表 12 基于集成学习的 A5 销售金额预测结果

日期	金额（元）
202306	18809994
202307	6347100

202308	4188581.3
202309	10039784
202310	5054294.5
202311	8770382
202401	3314082.8
202402	13138589
202403	5307279
202404	8622302

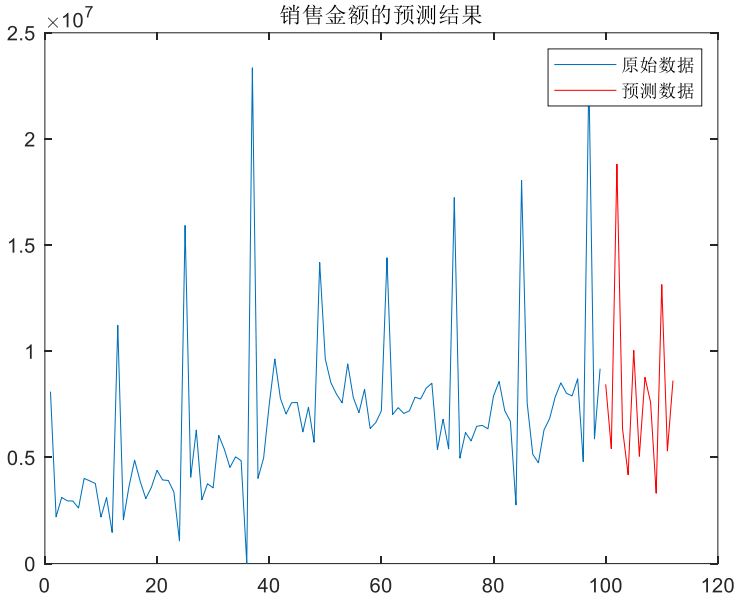

图 26 基于集成模型的 A5 销售金额预测结果可视化

6.3.3 预测结果修正

通过前面对销量和销售金额相互关系的分析发现，A5 品牌香烟的销量和销售金额之间存在强相互关系，这表明本文可以通过销量的预测结果进一步修正销售金额的预测结果，反之亦是如此。因此本文参考王粟等（2019）的做法，本文通过构造误差序列对预测结果进行进一步修正。下面是修正的具体步骤：

步骤一：构造误差序列。设销量各模态时间序列经过集成学习后的预测结果表示为：

$$\hat{u}_i = (\hat{u}_i^{(1)}, \hat{u}_i^{(2)}, \dots, \hat{u}_i^{(K)}) \tag{23}$$

则重构后的预测结果可以表示为：

$$\hat{Q} = \sum_{k=1}^{K} \hat{u}_k \tag{24}$$

设销量的原始数据集为$Q = (Q_1, Q_2, \dots, Q_n)$，则通过$E = Q - \hat{Q}$可可以得到误差序列$E$，且$E$可以表示为：

$$E = (e_1, e_2, \dots, e_n) \tag{25}$$

步骤二：使用　　模型对误差序列进行训练与预测。设销售金额数据集为$P = (P_1, P_2, \dots, P_n)$，则将$P$作为特征列输入，$E$作为目标列输出，可以实现对模型的训练。此时用$\hat{P} = (\hat{P}_{n+1}, \hat{P}_{n+2}, \dots, \hat{P}_{n+t})$可以预测得到$\hat{E} = (e_{n+1}, e_{n+2}, \dots, e_{n+t})$，其中$t$表示在原有数据集基础上继续预测$t$期。

步骤三：将销量的初步预测结果$\hat{Q} = (\hat{Q}_{n+1}, \hat{Q}_{n+2}, \dots, \hat{Q}_{n+t})$与销量的预测误差序列$\hat{E} = (e_{n+1}, e_{n+2}, \dots, e_{n+t})$进行求和重构，则可得到销量的最终预测值$Q_{pred} = \hat{Q} + \hat{E}$。

步骤四：类似步骤一到三的方法，实现对销售金额预测结果的修正。

利用 TVF_EMD_SVR 模型进行误差修正，TVF_EMD_SVR 模型效果及整体模型预测效果如下：

表 13　基于误差修正模型的 A5 销量预测结果评价

评价指标	TVF_EMD 模型（预测误差项）		误差修正效果	
RSME	0.62779	1.9796	0.62779	1.9795
R2	0.99318	0.99241	0.99998	0.99981
MAE	0.50604	1.7724	0.50604	1.7724

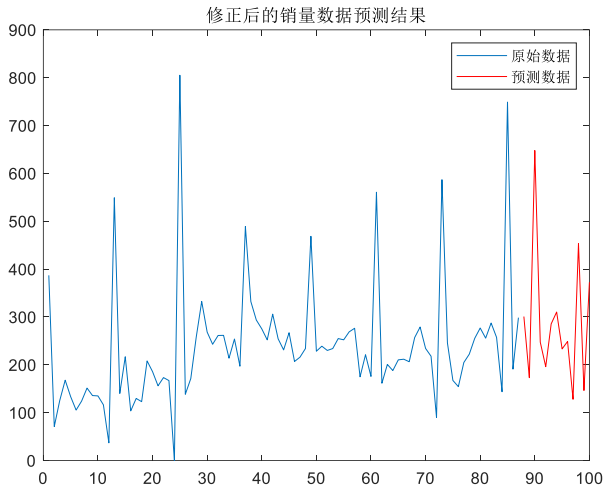

图 27　基于误差修正模型的 A5 销量数据预测结果

表 14　基于误差修正模型的 A5 销售金额预测结果评价

评价指标	TVF_EMD 模型（预测误差项）		误差修正效果	
RSME	17892.8054	76601.2566	17892.8438	76601.1797
R2	0.9928	0.98638	0.99998	0.99969
MAE	14869.464	58361.4642	14869.4941	58361.4297

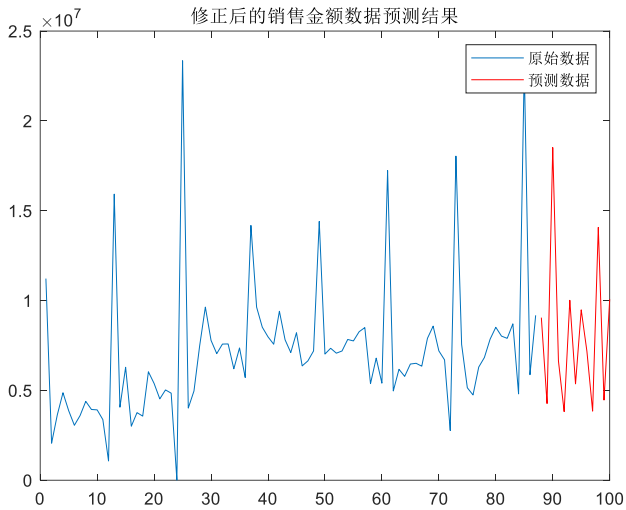

图 28　基于误差修正模型的 A5 销售金额数据预测结果

表 15　最终 A5 数据集预测结果

日期	销量（箱）	金额（元）
202306	647.82642	18809994
202307	247.35587	6347100
202308	196.06175	4188581.3
202309	285.52734	10039784
202310	310.34235	5054294.5
202311	233.20308	8770382
202401	128.00656	3314082.8
202402	453.18198	13138589
202403	146.40814	5307279
202404	372.54123	8622302

九、模型优缺点分析

9.1 优点

基于模态分解的预测模型在烟草销售数据预测中展现出了显著的优越性，主要体现在以下几个方面：

1. 特征增强：模态分解技术，如变分模态分解（VMD），能够将烟草销售数据这类复杂的时间序列分解为多个固有模态分量（IMFs），每个分量代表了数据中的不同频率、趋势或周期性的部分，从而增强了信号的特征，使得机器学习模型能够更容易捕捉到与预测任务相关的特征，提高预测准确性。

2. 降噪处理：在模态分解过程中，高频噪声通常被分配到高阶模态分量中，而低频信号和趋势则体现在低阶模态分量。通过去除或减小噪声分量的影响，可以净化信号，使得模型学习到更为纯净和有意义的信号特征，提升预测性能。

3. 多尺度分析：模态分解提供了信号的多尺度表示，使得模型能够同时考虑不同时

间尺度上的动态特征，这对于包含多种周期性和非线性模式的销售数据尤为重要。这种多分辨率分析能力有助于模型更好地理解和模拟复杂的时序行为。

4. 简化模型复杂度：分解后的各个模态分量往往具有更简单的结构，模型可能不需要那么复杂的结构就能达到良好的预测效果，这有助于减少过拟合的风险并提高模型的泛化能力。

5. 增强解释性：模态分解过程增加了模型输出的可解释性，因为每个模态分量都对应着信号的一个特定特征。这对于理解模型预测背后的业务逻辑非常重要。

6. 适应性处理非平稳性：许多时间序列是非平稳的，直接应用于这类序列的传统预测模型可能效果不佳。模态分解能够有效应对非平稳信号，因为它能够适应性地分解出随时间变化的模式，使得后续的预测模型能够更好地聚焦于这些变化的特征。

7. 集成学习优化：在销售预测中，集成学习方法如 Stacking 可以进一步提高预测性能。通过结合多个基学习器的预测结果，Stacking 模型能够平衡不同算法的优势，减少单一模型的预测误差，提高整体的预测精度。

综上所述，基于模态分解的预测模型通过其在特征提取、降噪、多尺度分析等方面的优势，结合集成学习策略，为烟草销售数据预测提供了一种高效、准确的解决方案。

9.2 缺点

尽管基于模态分解的预测模型在烟草销售数据预测中具有显著的优势，但也存在一些潜在的缺点和局限性：

1. 计算成本：模态分解，尤其是变分模态分解（VMD）等，可能需要较高的计算资源和时间，特别是对于大规模数据集。这可能限制了模型在需要实时或近实时预测的应用中的使用。

2. 参数选择：模态分解技术通常涉及多个参数的选择（如分解层数、正则化系数等），这些参数的设定对分解结果有显著影响。合适的参数选择可能需要专业知识和大量的实验调整。

参考文献

[1] 王粟,江鑫,曾亮,等.基于 VMD-DESN-MSGP 模型的超短期光伏功率预测[J].电网技术,2020,44(03):917-926.DOI:10.13335/j.1000-3673.pst.2019.0958.

[2] 孙毅,鲍荟谕,郑顺林,等.基于数据分解与知识蒸馏的多能负荷与碳排放联合预测模型[J/OL].中国电机工程学报,1-14[2024-07-27].http://kns.cnki.net/kcms/detail/11.2107.tm.20240528.1644.009.html.

[3] 刘刚,李嘉翔,魏文浩,等.基于多目标优化组合模型的电力负荷预测[J].兰州大学学报(自然科学版),2023,59(03):380-386.DOI:10.13885/j.issn.0455-2059.2023.03.013.

[4] 张雨田,石军南,张怀清,等.洞庭湖湿地植被时空动态及其驱动力分析[J/OL].林业科学,1-20[2024-07-27].http://kns.cnki.net/kcms/detail/11.1908.S.20240725.1613.002.html.

[5] 贾世会,刘立夫,迟晓妮,等.基于 BWO 和 WOA 的 VMD-LSTM 短期风速预测[J/OL].郑州大学学报(工学版),1-8[2024-07-29].https://doi.org/10.13705/j.issn.1671-6833.2024.06.014.

[6] 贾世会,刘立夫,迟晓妮,等.基于 BWO 和 WOA 的 VMD-LSTM 短期风速预测[J/OL].郑州大学学报(工学版),1-8[2024-07-29].https://doi.org/10.13705/j.issn.1671-6833.2024.06.014.

[7] 王瑞,李虹锐,逯静,等.基于 VMD-LILGWO-LSSVM 短期风电功率预测[J].河南理工大学学报(自然科学版),2024,43(02):128-136.DOI:10.16186/j.cnki.1673-9787.2021110135.

附录